

Universidad Nacional de San Agustín de Arequipa

AÑO DE LA RECUPERACIÓN Y CONSOLIDACIÓN DE LA  
ECONOMÍA PERUANA



ESCUELA PROFESIONAL DE CIENCIA DE LA COMPUTACIÓN  
Temas en Inteligencia Artificial

---

## LABORATORIO 4

MULTI LAYER PERCEPTRON

A-2025

---

Profesor: MSc. R. Jesús Cárdenas Talavera

Javier Wilber Quispe Rojas

# Índice

|  |   |
|--|---|
| Índice   | 1 |
| 1 Almacene los datos del entrenamiento y analice la curva de pérdida y precisión.  | 2 |
| 2 Almacene los datos del entrenamiento y analice la curva de pérdida y precisión.  | 3 |
| 3 Muestre un gráfico de los datos resultantes del entrenamiento y analice en cuantas épocas (o error mínimo) del entrenamiento se llega a obtener un modelo óptimo de clasificación. | 4 |
| 4 ¿Qué precisión se puede alcanzar con la mitad de épocas?   | 5 |
| 5 Vuelva a entrenar el modelo con el doble de épocas del modelo óptimo y analice el gráfico obtenido del entrenamiento, ¿Se obtiene un modelo mejor?                                 | 6 |
| 6 Prueba con Data del Profesor   | 8 |

1. Almacene los datos del entrenamiento y analice la curva de pérdida y precisión.

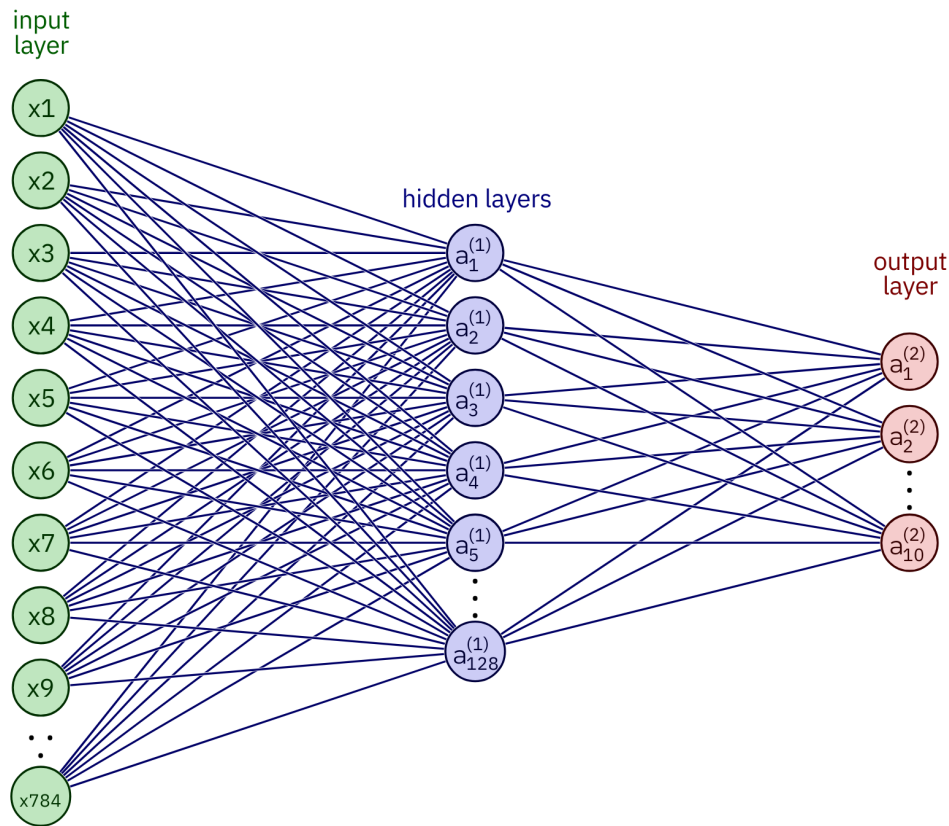


Figura 1: Arquitectura de MLP

La figura representa la arquitectura de un perceptrón multicapa (MLP) diseñado para clasificación, que consta de tres capas principales:

- **Capa de entrada:** Contiene 784 nodos (representados como  $x_1, x_2, \dots, x_{784}$ ), correspondientes a los píxeles normalizados de una imagen de 28x28, como en el dataset MNIST. Esta capa recibe los datos crudos de entrada para ser procesados.
- **Capa oculta:** Está compuesta por 128 neuronas, etiquetadas como  $a_1^{(1)}, a_2^{(1)}, \dots, a_{128}^{(1)}$ . Cada neurona de esta capa recibe la salida ponderada de todas las neuronas de la capa de entrada, aplicando la función de activación ReLU para introducir no linealidad y permitir que el modelo capture relaciones complejas en los datos.
- **Capa de salida:** Formada por 10 neuronas, indicadas como  $a_1^{(2)}, a_2^{(2)}, \dots, a_{10}^{(2)}$ , correspondientes a las 10 clases posibles de dígitos (0-9) en el problema de clasificación. Esta capa utiliza la función softmax para convertir las salidas en probabilidades de pertenencia a cada clase.

El diagrama muestra conexiones densas (fully connected) entre todas las neuronas adyacentes, representando cómo cada neurona recibe señales de todas las neuronas de la capa anterior. Debido al gran número de neuronas en la capa de entrada y oculta, el gráfico solo muestra los primeros y últimos nodos de cada capa, con puntos suspensivos indicando nodos omitidos para mantener claridad visual.

Esta arquitectura es adecuada para tareas de reconocimiento de dígitos manuscritos, equilibrando la complejidad del modelo con la capacidad para generalizar a partir de los datos de entrenamiento.

## 2. Almacene los datos del entrenamiento y analice la curva de pérdida y precisión.




Figura 2: Curva de Perdida y Precision

En el gráfico se observa la evolución del **error cuadrático medio** (curva azul) y la **precisión** (curva naranja) durante 30 épocas de entrenamiento.

- **Error cuadrático medio:** Se aprecia una reducción continua y sostenida del error a medida que avanzan las épocas. Esto indica que el modelo está mejorando su capacidad para ajustar las predicciones a los datos reales. La curva presenta una caída rápida en las primeras épocas y luego un descenso más gradual, lo que es típico en procesos de optimización donde el modelo encuentra soluciones cada vez más refinadas.
- **Precisión:** La precisión aumenta rápidamente durante las primeras épocas, mostrando que el modelo mejora rápidamente en la clasificación correcta de las muestras. Posteriormente, la tasa de mejora se desacelera y la curva se estabiliza, alcanzando un valor alrededor de 0.85, lo que indica que el modelo es capaz de clasificar correctamente aproximadamente el 85 % de las muestras en el conjunto de entrenamiento.
- **Comportamiento conjunto:** El descenso del error y el aumento de la precisión son coherentes y esperados durante un entrenamiento efectivo. La relación inversa entre estas dos métricas confirma que a medida que el modelo reduce el error, su capacidad de predicción mejora.
- **Estabilidad:** Hacia el final del entrenamiento, ambas curvas muestran una tendencia a estabilizarse, lo que sugiere que el modelo ha alcanzado un punto de convergencia y que seguir entrenando más tiempo podría aportar mejoras marginales.




Figura 3: Matriz de Confusion con 30 épocas

3. Muestre un gráfico de los datos resultantes del entrenamiento y analice en cuantas épocas (o error mínimo) del entrenamiento se llega a obtener un modelo óptimo de clasificación.




Figura 4: época optima y época eficiente

El gráfico muestra la evolución del error cuadrático medio (curva azul) y la precisión (curva naranja) a lo largo de 30 épocas de entrenamiento.

- **Error mínimo y época óptima:** La línea roja vertical marca la época 30, momento en el cual se alcanza el error cuadrático medio más bajo y la máxima precisión registrada durante el entrena-

miento. Esto indica que el modelo óptimo se obtiene en esta época, logrando el mejor balance entre minimizar el error y maximizar la precisión.

- **Época eficiente:** La línea verde vertical señala la época 23, donde la tasa de mejora en precisión comienza a ser marginal. A partir de este punto, continuar entrenando aporta beneficios muy pequeños en precisión, por lo que detener el entrenamiento en esta época puede ahorrar tiempo y recursos sin sacrificar significativamente el desempeño.
- **Número de épocas para el modelo óptimo:** Aunque la mejor precisión se alcanza en la época 30, un buen compromiso entre rendimiento y eficiencia se logra en la época 23. Por lo tanto, se recomienda considerar estas dos épocas según las necesidades de precisión o eficiencia en el entrenamiento.

#### 4. ¿Qué precisión se puede alcanzar con la mitad de épocas?

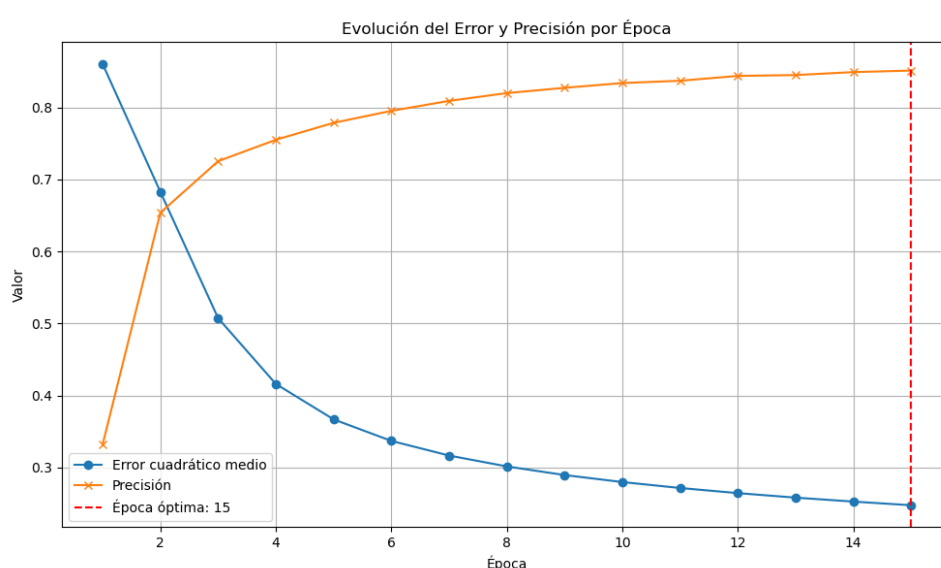


Figura 5: Grafica Con 15 epocas

El modelo fue entrenado durante 30 épocas, alcanzando una precisión máxima cercana al 86 % en la última época. Al analizar la mitad de las épocas, es decir, la época 15, observamos que la precisión es aproximadamente 85 %, lo que representa cerca del 99 % de la precisión máxima.

Esto indica que gran parte del aprendizaje ocurre en las primeras etapas del entrenamiento, donde el modelo ajusta rápidamente sus parámetros y mejora su capacidad predictiva. A partir de ese punto, las mejoras son menores y la curva de precisión tiende a estabilizarse.

Desde un punto de vista práctico, entrenar solo hasta la época 15 permite ahorrar tiempo y recursos con una pérdida mínima de precisión, siendo un buen compromiso entre eficiencia y desempeño. Sin embargo, para aplicaciones que requieran la máxima precisión, continuar hasta la época 30 puede ser justificado.

La época 15 representa un punto eficiente para detener el entrenamiento, logrando una precisión alta con menor costo computacional.




Figura 6: Matriz de Confusion con 15 épocas

5. Vuelva a entrenar el modelo con el doble de épocas del modelo óptimo y analice el gráfico obtenido del entrenamiento, ¿Se obtiene un modelo mejor?

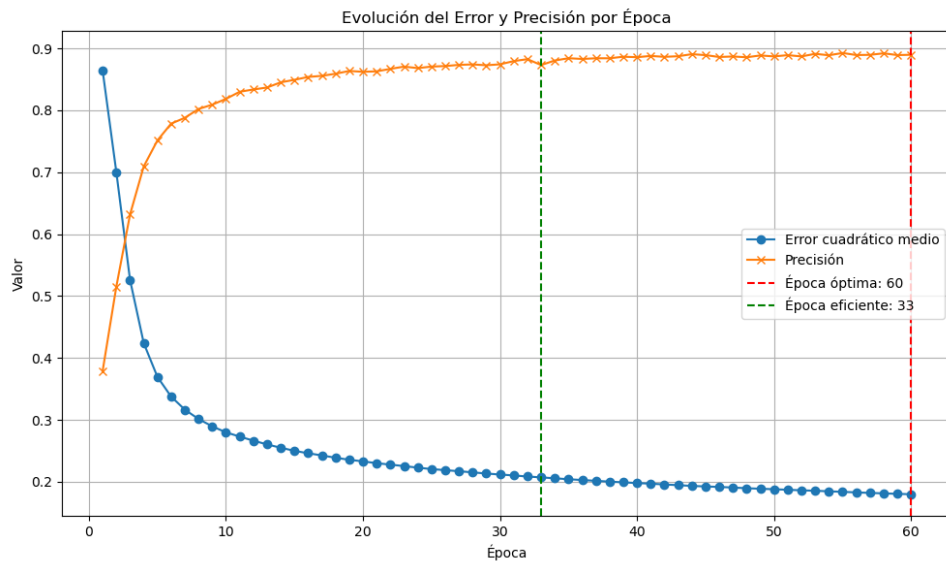


Figura 7: Grafica Con 60 épocas

El modelo entrenado durante 60 épocas alcanza una precisión máxima de aproximadamente **88.97 %** en la última época, con un error cuadrático medio de 0.1799.

Comparado con el entrenamiento inicial de 30 épocas, donde la precisión máxima fue cercana al 86 %, este modelo mejora su capacidad de clasificación en alrededor de 3 puntos porcentuales.

Sin embargo, esta mejora se obtiene a costa de duplicar el tiempo y los recursos de entrenamiento. Gran parte del aprendizaje efectivo ocurre antes, cerca de la época eficiente (época 33), donde la precisión ya está próxima a su máximo y las ganancias posteriores son marginales.

Por lo tanto, aunque entrenar por 60 épocas permite obtener un modelo mejor, la decisión de continuar entrenando debe basarse en un balance entre la necesidad de máxima precisión y las limitaciones computacionales. En muchos casos, detener el entrenamiento en la época eficiente es una estrategia eficiente sin sacrificar significativamente el desempeño.




Figura 8: Matriz de Confusion con 60 epocas



## 6. Prueba con Data del Profesor




Figura 9: Test Con la data del profesor

El modelo de clasificación utilizado presentó una precisión total de 0.2250, lo que indica que solo el 22.5% de las predicciones fueron correctas. Este bajo rendimiento sugiere que el modelo no ha logrado generalizar correctamente.

Uno de los problemas más probables es que las imágenes de prueba podrían ser significativamente diferentes de las imágenes utilizadas en el entrenamiento, lo que dificulta la capacidad del modelo para realizar predicciones precisas. Además, podría existir un desbalance en las clases o un preprocesamiento inadecuado de los datos, lo que afectaría la efectividad del modelo.

En conclusión, para mejorar el rendimiento del modelo, sería necesario revisar las condiciones de los datos de prueba, probar diferentes enfoques de preprocesamiento y considerar el uso de modelos alternativos que puedan adaptarse mejor a las características de las imágenes.